

## Informe de Experimentación y Pruebas

### Versión del modelo / herramienta

- LLM: Groq (modelo por defecto: `llama-3.1-8b-instant`; temperatura 0.6).
- Backend: FastAPI + Python.
- Parsing y post-procesamiento propio (limpieza, deduplicación, truncado narrativo).

### Prompts utilizados

System Prompt:

'''

Eres un asesor ejecutivo experto en 'Scaling Up' (Verne Harnish). Recibirás puntajes en People, Strategy, Execution y Cash (0-10) más notas del usuario. Genera: (1) diagnóstico narrativo claro y empático, (2) top 3 prioridades, (3) recomendaciones accionables por prioridad, usando lenguaje sencillo y concreto. Sé breve pero sustancial.

'''

User Prompt genérico:

'''

Puntajes -> People: {people}, Strategy: {strategy}, Execution: {execution}, Cash: {cash}.

Notas del usuario (resúmenes):

- {nota\_1}

- {nota\_2}

- {nota\_3}

...

'''

Resumen rápido: se reusa el prompt base y se reduce la longitud del narrativo a ~360 caracteres en post-proceso.

## Resultados obtenidos

- Generación consistente de narrativas breves (2–6 líneas) con contexto de puntajes y tono empático.
- Prioridades generadas alineadas a áreas de menor puntaje (People y Cash en pruebas).
- Recomendaciones accionables: entre 5 y 12 ítems crudos; tras deduplicación quedan 6–10 limpias.
- Tiempo medio de respuesta del modelo (REST) < 3 s en entorno local.
- PDF ejecutivo generado sin solapamiento visual y sin gráficos (formato limpio).

## Ajustes realizados

1. Eliminación de gráfico radar para evitar ruido visual y peso de activos.
2. Deduplicación de prioridades y recomendaciones (filtro set + normalización).
3. Limpieza de encabezados redundantes (“Top 3 Prioridades”, “Recomendaciones”) fuera del cuerpo narrativo.
4. Truncado narrativo para resumen rápido (máx. 360 caracteres preservando palabra completa).
5. Fallback narrativo fijo cuando el servicio Groq devuelve error (HTTP  $\geq$  400).
6. Cambio de layout PDF: puntajes en una sola línea, tipografías uniformes, envoltura de texto con saltos de página controlados.
7. Eliminación de repetición numérica en listado (casos de doble enumeración 1., 1.).

## Observaciones y aprendizajes

- El modelo tiende a repetir encabezados si el prompt no enfatiza “sin duplicar títulos”; mitigado vía post-proceso.
- Un límite suave de caracteres en resumen rápido mejora legibilidad sin sacrificar contexto.
- Deduplicar antes de almacenar reduce ruido en historial y PDF.
- Separar responsabilidades (prompt vs. formateo) facilita futuros cambios de modelo sin tocar interfaz.
- La ausencia del gráfico aumenta claridad percibida del informe por usuarios ejecutivos.
- Fallback controlado evita bloquear generación de prioridades ante fallos temporales del servicio LLM.